

АНАЛИТИЧЕСКИЙ ОТЧЁТ

Heart Failure Dataset

Сердечно-сосудистые заболевания

70 000

записей

13

признаков

0

пропущ. значений

~30-65

лет (возраст)

1. Введение

Датасет Heart Failure Dataset представляет собой набор медицинских данных, собранных для задачи бинарной классификации — предсказания наличия или отсутствия сердечно-сосудистого заболевания (ССЗ) у пациентов. Сердечно-сосудистые заболевания являются ведущей причиной смертности во всём мире, поэтому разработка точных предиктивных моделей имеет критическое значение для ранней диагностики и профилактики.

Данные содержат демографическую информацию о пациентах, объективные клинические измерения (артериальное давление, рост, вес) и субъективные показатели образа жизни (курение, употребление алкоголя, физическая активность). Целевая переменная `cardio` указывает наличие (1) или отсутствие (0) ССЗ.

Общая характеристика датасета

Параметр	Значение
Количество записей	70 000
Количество признаков	13 (включая целевую переменную)
Входные признаки	12
Целевая переменная	cardio (бинарная: 0 / 1)
Пропущенные значения	Отсутствуют (0 по всем столбцам)
Тип данных	Все признаки — целочисленные (int64)
Баланс классов	Класс 0: 35 021 (50.03%) Класс 1: 34 979 (49.97%)
Возрастной диапазон	~30 — 65 лет (возраст хранится в днях)
Источник	Публичный датасет (Kaggle / открытые источники)

2. Описание признаков (столбцов)

Датасет содержит 13 столбцов. Признаки делятся на три категории: объективные (измеренные клинически), субъективные (со слов пациента) и целевая переменная. Ниже приведено подробное описание каждого признака.

	id	int64	Идентификатор
Название (RU):	Уникальный идентификатор пациента		
Описание:	Порядковый номер записи. Значения от 0 до 99 999. Не несёт информационной нагрузки для моделирования — должен быть исключён из обучающих признаков.		
Диапазон:	0 — 99 999		
Значения:	Уникальные целые числа		

age

int64

Демографический

Название (RU):	Возраст пациента (в днях)
Описание:	Возраст пациента выражен в днях, а не в годах. Для получения возраста в годах необходимо разделить на 365. Диапазон соответствует примерно 30–65 годам. Среднее значение ~19 469 дней (~53.3 года).
Диапазон:	10 798 — 23 713 дней (~30–65 лет)
Значения:	Непрерывное числовое значение

gender

int64

Демографический

Название (RU):	Пол пациента
Описание:	Кодировка пола: 1 — женщина, 2 — мужчина. В датасете преобладают женщины: 45 530 (65%) против 24 470 (35%) мужчин. При анализе важно учитывать гендерный дисбаланс.
Диапазон:	1, 2
Значения:	1 = Женщина (65.0%), 2 = Мужчина (35.0%)

height

int64

Объективный

Название (RU):	Рост (в сантиметрах)
Описание:	Рост пациента в сантиметрах. Среднее значение ~164 см, стандартное отклонение ~8 см. Датасет содержит выбросы: минимальное значение 55 см и максимальное 250 см явно аномальны и требуют очистки при предобработке данных.
Диапазон:	55 — 250 см (медиана: 165 см)
Значения:	Непрерывное числовое значение

weight

int64

Объективный

Название (RU):	Вес (в килограммах)
Описание:	Вес пациента в килограммах. Среднее значение ~74 кг. Вместе с ростом используется для расчёта ИМТ (индекса массы тела), который является важным предиктором ССЗ. Встречаются выбросы: вес 10 кг и 200 кг требуют проверки.
Диапазон:	10 — 200 кг (медиана: 72 кг)
Значения:	Непрерывное числовое значение

ap_hi

int64

Объективный

Название (RU):	Систолическое артериальное давление (верхнее)
Описание:	Систолическое (верхнее) артериальное давление в мм рт. ст. Норма — 120 мм рт. ст., гипертония — выше 140. Датасет содержит значительные выбросы: отрицательные значения (-150) и экстремально высокие (16 020) являются ошибками ввода данных. 50-й перцентиль: 120 мм рт. ст.
Диапазон:	-150 — 16 020 (норма: 90–140 мм рт. ст.)
Значения:	Непрерывное числовое значение

ap_lo

int64

Объективный

Название (RU):	Диастолическое артериальное давление (нижнее)
Описание:	Диастолическое (нижнее) артериальное давление в мм рт. ст. Норма — 80 мм рт. ст., гипертония — выше 90. Также содержит выбросы: отрицательные значения (-70) и максимум 11 000 mm Hg. Медиана: 80 мм рт. ст. Высокое диастолическое давление — ключевой фактор риска ССЗ.
Диапазон:	-70 — 11 000 (норма: 60–90 мм рт. ст.)
Значения:	Непрерывное числовое значение

cholesterol

int64

Объективный

Название (RU):	Уровень холестерина
Описание:	Уровень холестерина крови, закодированный в три категории: 1 — норма, 2 — выше нормы, 3 — значительно выше нормы. Большинство пациентов имеют нормальный уровень (74.8%). Повышенный холестерин — один из главных факторов риска атеросклероза и ССЗ.
Диапазон:	1, 2, 3
Значения:	1 = Норма (74.8%) 2 = Выше нормы (13.6%) 3 = Значит. выше нормы (11.5%)

gluc

int64

Объективный

Название (RU):	Уровень глюкозы в крови
Описание:	Уровень глюкозы в крови, закодированный аналогично холестерину: 1 — норма, 2 — выше нормы, 3 — значительно выше нормы. Подавляющее большинство пациентов с нормальным уровнем (84.97%). Высокий уровень глюкозы связан с диабетом — фактором риска ССЗ.
Диапазон:	1, 2, 3
Значения:	1 = Норма (84.97%) 2 = Выше нормы (7.4%) 3 = Значит. выше нормы (7.6%)

smoke

int64

Субъективный

Название (RU):	Курение
Описание:	Бинарный признак: курит ли пациент. 1 — курит, 0 — не курит. Курящих пациентов в датасете 8.8% (6 169 человек). Курение — установленный фактор риска сердечно-сосудистых заболеваний.
Диапазон:	0, 1
Значения:	0 = Не курит (91.2%) 1 = Курит (8.8%)

alco

int64

Субъективный

Название (RU):	Употребление алкоголя
Описание:	Бинарный признак: употребляет ли пациент алкоголь. 1 — употребляет, 0 — не употребляет. Употребляющих алкоголь пациентов 5.4% (3 764 человека). Признак является субъективным — со слов пациента.
Диапазон:	0, 1
Значения:	0 = Не употребляет (94.6%) 1 = Употребляет (5.4%)

active

int64

Субъективный

Название (RU):	Физическая активность
Описание:	Бинарный признак: физически ли активен пациент. 1 — активен, 0 — не активен. 80.4% пациентов указали, что ведут физически активный образ жизни. Регулярная физическая активность снижает риск ССЗ.
Диапазон:	0, 1
Значения:	0 = Не активен (19.6%) 1 = Активен (80.4%)

cardio

int64

Целевая переменная

Название (RU):	Наличие сердечно-сосудистого заболевания (ЦЕЛЕВОЙ ПРИЗНАК)
Описание:	Бинарная целевая переменная: наличие (1) или отсутствие (0) сердечно-сосудистого заболевания у пациента. Датасет практически идеально сбалансирован: 35 021 здоровых (50.03%) и 34 979 с ССЗ (49.97%). Это упрощает обучение моделей классификации.
Диапазон:	0, 1
Значения:	0 = Нет ССЗ (50.03%) 1 = Есть ССЗ (49.97%)

3. Статистический обзор

3.1. Описательная статистика числовых признаков

Возраст (age): хранится в днях. Минимум — 10 798 дней (~29.6 лет), максимум — 23 713 дней (~65 лет), медиана — 19 703 дней (~54 года), среднее — 19 469 дней (~53.3 года), стандартное отклонение — 2 467 дней (~6.8 лет).

Рост (height): минимум — 55 см, максимум — 250 см (оба значения являются выбросами), медиана — 165 см, среднее — 164.4 см, стандартное отклонение — 8.2 см.

Вес (weight): минимум — 10 кг, максимум — 200 кг (оба значения являются выбросами), медиана — 72 кг, среднее — 74.2 кг, стандартное отклонение — 14.4 кг.

Систолическое давление (ap_hi): медиана — 120 мм рт. ст., среднее — 128.8 мм рт. ст. Датасет содержит выбросы: минимум -150 и максимум 16 020 мм рт. ст. Из-за выбросов стандартное отклонение аномально велико — 154 мм рт. ст.

Диастолическое давление (ap_lo): медиана — 80 мм рт. ст., среднее — 96.6 мм рт. ст. Также содержит выбросы: минимум -70 и максимум 11 000 мм рт. ст., стандартное отклонение — 188.5 мм рт. ст.

3.2. Распределение категориальных признаков

Признак	Категория	Кол-во	Доля
gender	1 — Женщина	45 530	65.0%
	2 — Мужчина	24 470	35.0%
cholesterol	1 — Норма	52 385	74.8%
	2 — Выше нормы	9 549	13.6%
	3 — Значительно выше нормы	8 066	11.5%
gluc	1 — Норма	59 479	85.0%
	2 — Выше нормы	5 190	7.4%
	3 — Значительно выше нормы	5 331	7.6%
smoke	0 — Не курит	63 831	91.2%
	1 — Курит	6 169	8.8%
alco	0 — Не употребляет	66 236	94.6%
	1 — Употребляет	3 764	5.4%
active	0 — Не активен	13 739	19.6%
	1 — Активен	56 261	80.4%
cardio	0 — Нет ССЗ	35 021	50.0%
	1 — Есть ССЗ	34 979	50.0%

4. Качество данных и выбросы

Несмотря на отсутствие пропущенных значений, датасет содержит ряд аномалий, которые необходимо устранить перед построением модели:

Систолическое давление (ap_hi): содержит отрицательные значения (минимум -150) и экстремально высокие значения (максимум 16 020 мм рт. ст.), что физически невозможно. Рекомендуется оставить только записи в диапазоне 60–250 мм рт. ст.

Диастолическое давление (ap_lo): аналогичная проблема — значения от -70 до 11 000 мм рт. ст. Рекомендуется фильтрация до диапазона 40–200 мм рт. ст.

Рост (height): значения 55 см и 250 см физиологически невозможны для взрослого человека. Рекомендуется оставить записи с ростом в диапазоне 100–220 см.

Вес (weight): значения 10 кг и 200 кг являются вероятными ошибками ввода. Рекомендуется фильтрация до диапазона 30–180 кг.

Соотношение ap_hi и ap_lo: в ряде записей диастолическое давление превышает систолическое (ap_lo > ap_hi), что физически невозможно. Такие записи следует удалить из датасета.

5. Области применения датасета

Бинарная классификация	Основная задача: предсказание наличия ССЗ (cardio = 0 или 1). Датасет хорошо сбалансирован, что позволяет применять стандартные метрики (accuracy, F1-score, AUC-ROC) без специальных техник балансировки.
Анализ факторов риска	Изучение корреляции между признаками (давление, холестерин, возраст, ИМТ) и вероятностью ССЗ. Построение профилей риска для различных групп пациентов.
Предобработка данных	Датасет содержит реальные выбросы и аномалии, что делает его отличным учебным материалом для отработки техник очистки данных.
Машинное обучение	Подходит для обучения и сравнения классических алгоритмов: Logistic Regression, Random Forest, XGBoost, SVM, KNN, а также нейронных сетей.
Инженерия признаков	Создание производных признаков: ИМТ (weight/height^2), пульсовое давление ($\text{ap_hi} - \text{ap_lo}$), перевод возраста в годы.

6. Заключение

Heart Failure Dataset является высококачественным, хорошо сбалансированным набором данных для задачи прогнозирования сердечно-сосудистых заболеваний. Датасет охватывает широкий спектр медицинских показателей: от демографических данных до клинических измерений и факторов образа жизни.

Ключевые преимущества датасета: отсутствие пропущенных значений, сбалансированность классов целевой переменной (50/50), достаточный объём данных (70 000 записей) для построения надёжных моделей машинного обучения.

Основные задачи при предобработке: устранение выбросов в признаках артериального давления (ar_hi, ar_lo), роста и веса, создание производных признаков (ИМТ, возраст в годах), а также кодирование категориальных переменных при необходимости.